Data Clean Rooms

Cours complet pour Growth Hackers

Agenda du cours

Session 1

Introduction aux DCR

Concepts & Use Cases

Session 2

Architecture & Fonctionnement

Démonstrations techniques

Session 3

Sécurité & Conformité

RGPD et protection des données

Session 4

Optimisation & ROI

Tendances et projets

SESSION 1

Introduction aux Data Clean Rooms

Définition: Data Clean Rooms

Un environnement sécurisé où les données sensibles peuvent être partagées et analysées sans exposition directe

Solution de collaboration qui protège la confidentialité des données tout en permettant l'analyse

Technologie clé dans l'ère post-cookies tiers

Alternative conforme à RGPD pour le partage de données B2B

Contexte: Pourquoi les DCR maintenant?

Suppression des cookies tiers (Chrome, Safari, Firefox)

Conformité RGPD: responsabilité croissante du traitement

Demande d'accès aux données propriétaires (audiences, comportement)

Besoin de collaboration inter-entreprises sans risque légal

Marché qui explose: Google, Amazon, Palantir, Adobe (2021-2024)

Paysage des solutions DCR (2024)

Grands acteurs technologiques:

Google Ads Data Manager

Amazon AWS Clean Rooms

Adobe Data Clean Room

Spécialistes indépendants:

Palantir Apollo

Habu

Terbine

Use Case 1: Marques & Retailers

Problème:

Marque X veut analyser comment ses clients achètent chez Retailer Y

Retailer refuse de partager directement les données clients

Solution DCR:

Marque envoie ses IDs clients chiffrés

Retailer croise avec ses données dans la DCR

Résultats: insights agrégés (pas d'accès aux lignes)

Use Case 2: Éditeurs & Annonceurs

Problème:

Éditeur A et B veulent coordonner leurs audiences sans les revendre

Annonceur C veut mesurer la couverture totale

Solution DCR:

Chaque éditeur télécharge ses audiences anonymisées

Calcul d'overlap et de couverture dans l'environnement sécurisé

Pas de royalties échangées directement

Use Case 3: Match-making CRM

Problème:

Marque A (15k clients) + Marque B (20k clients): crossselling

Aucune veut révéler sa customer list

Solution DCR:

Hash les emails de chaque client (MD5, SHA256)

Croise les hashs dans la DCR pour identifier les clients communs

Marques restent anonymes pour les non-matches

Avantages des Data Clean Rooms

Confidentialité: pas d'accès direct aux données brutes

Conformité: RGPD-ready avec contracts de sous-traitance clairs

Collaboration: déverrouille données tierces impossibles à acheter

Insights à grande échelle: croisement sans centralisation

ROI: insights supérieurs à analytics 1st-party seul

Défis et limitations actuels

Coûts: infrastructure expensive, tarification par requête

Adoption lente: ecosystème still maturing

Fragmentation: chaque plateforme a son proprio ecosystem

Compétences: data science + data engineering skills requis

Interopérabilité: difficile de croiser données entre DCRs différentes

Résumé Session 1

À retenir:

DCRs = infrastructure critique pour l'ère post-cookies

Cas d'usage business réels: retail, media, CRM

Avantage concurrentiel: accès à données impossible avant

Investissement requis: coûts & compétences internes

SESSION 2

Architecture & Fonctionnement

Architecture générale d'une DCR

Composants clés:

1. Data Ingestion Layer: upload sécurisé de données

2. Storage & Compute: environnement isolé (conteneurs, VM, enclaves)

3. Query Engine: SQL/Python avec restrictions (no raw data export)

4. Analytics & Results: output agrégés seulement

5. Audit & Compliance: logs de toute activité

Isolation Technique

Comment ça marche:

Conteneurisation: chaque client dans conteneur Docker isolé

Enclaves sécurisées: Intel SGX ou AMD SEV (matériel)

Chiffrement: données at-rest + in-transit + parfois in-use

Network isolation: zéro accès sortant, API gatekeeping

Ingestion de données

```
Upload CSV/Parquet
[Validation schema]
↓
[De-duplication]
↓
[Encryption with customer key]
↓
[Stored in isolated DB]
```

Formats: CSV, Parquet, JSON, Database direct (API)

Formats recommandés: Parquet (colonnaire, compressé)

Moteurs de query

SQL (Standard):

SELECT avec restrictions: NO * (colonnes explicites)

Agrégations obligatoires pour data sensitivity

Exemples: Google BigQuery, Snowflake, DuckDB

Custom Engines:

Palantir Object Graph, AWS CleanRooms analytics

Limitations de query (DLP)

Rules appliquées automatiquement:

Row limit: MAX(1000) rows output par défaut

Aggregation minimum: GROUP BY avec COUNT >= 5 ou 10

Column exclusion: ID, emails, PII automatiquement masqués

Rate limiting: max 100 queries/hour

Output redaction: nombres arrondis (ex: 1,234 → 1,200)

Workflow d'utilisation

```
User 1: Upload customer_list.csv
User 2: Upload transaction_data.csv
↓
Common queries (SQL):
SELECT segment, COUNT(*)
FROM user1_data u
JOIN user2_data t ON u.email_hash = t.email_hash
GROUP BY segment
↓
Result: Summary table
```

Toutes les queries loggées et auditées

Cas réel: AWS Data Exchange + CleanRooms

Scénario:

Retailer X (données clients) + Data Vendor Y (données démographiques)

Workflow:

1. Retailer creates collaboration
2. Vendor provides encrypted dataset
3. Join on email_hash
4. Query: segment affinity (age x purchase frequency)
5. Output: insights CSV pour retailer seulement

Cas réel: Google Ads Data Manager

Pour Agencies & Brands:

Sync CRM data → Google ADH (Ads Data Hub)

Cross-media measurement: Search + Display + Video

Query modèles pré-builts (Google fourni)

Aggregations strictes: min 100 users per group

Output: conversion rates, ROAS by segment

Stack recommandée pour démarrer

Pour petites équipes (< 1M rows):

DuckDB en-process + encryption (SQLite moderne)

Pour medium scale (1M - 1B rows):

Snowflake (compute séparé) ou BigQuery

Pour enterprise:

Palantir, AWS CleanRooms, ou custom solution

Résumé Session 2

À retenir:

Architecture = isolation + encryption + controlled access

DLP rules appliquées automatiquement (row limits, aggregations)

SQL queries restreintes, output agrégé seulement

Tooling: choix entre hyperscalers vs spécialistes

SESSION 3

Sécurité & Conformité

Menaces courantes

Attaques possibles:

1. Re-identification: déduire identité de données anonymisées

2. Inference attacks: deviner valeurs manquantes

3. Collusion: multiples queries pour extraire raw data

4. Insider threat: admin accès abusif

5. Insuffisance aggregation: min count trop bas

Protection contre re-identification

Techniques:

K-anonymity: chaque row identique à min K autres

Differential privacy: bruit aléatoire ajouté aux résultats

Data masking: supprimer colonnes sensibles (ID, email, phone)

Bucketing: grouper âges (10-20, 21-30) instead exact

Differential Privacy (DP)

```
Real: SELECT COUNT(*) FROM users
Where segment = 'high_value'
Result: 4,523
↓
[Add Laplace noise: scale=100]
↓
DP result: 4,589 (privacy guarantee)
```

DP = math guarantee qu'ajouter/retirer 1 row change peu

Trade-off: utility vs privacy (plus bruit = plus protection)

RGPD: Compliance dans une DCR

Articles clés:

Art. 6 (Legal basis): contrat ou consentement nécessaire

Art. 9 (Special data): biometric, health, political = forbidden

Art. 32 (Security): must implement reasonable protections

Art. 28 (Data Processor): contrat de sous-traitance

DPIA (impact assessment): requise si high-risk

Data Processing Agreement (DPA)

DCR Provider MUST fournir:

Scope: quelles données, comment traitées

Duration: combien longtemps conservées

Security measures: encryption, audit logs

Subprocessors: qui d'autre peut accéder?

Data subject rights: how to delete (right to erasure)

Auditing & Monitoring

Logs détaillés pour chaque query:

Qui: user account + IP address

Quand: timestamp (UTC)

Quoi: SQL text + data sources accessed

Résultat: rows returned + success/failure

Rétention: min 1 an pour RGPD compliance

Checklist sécurité (Évaluations DCR)

- ✓ Chiffrement at-rest (AES-256) et in-transit (TLS 1.2+)
- ✓ Authentification multi-factor (MFA)
- ✓ Row-level security (RLS) par data owner
- ✓ Query DLP avec min aggregation count >= 5-10
- ✓ Audit logs immuables (append-only)
- ✓ Incident response plan documenté
- ✓ SOC 2 Type II ou ISO 27001 certification

Résumé Session 3

À retenir:

Sécurité = multi-layered: encryption + DP + aggregation

Re-identification risques réels = K-anonymity + DP obligatoire

RGPD = DPA contrat, droit à l'oubli, audit trails

Évaluations = SOC 2 / ISO 27001 certifications requis

SESSION 4

Optimisation & ROI

KPIs pour mesurer ROI

Business metrics:

ROAS lift: +15-30% vs baseline

Customer acquisition cost (CAC): -20% reduction

Lifetime value (LTV): +25% higher

Technical metrics:

Data freshness: lag entre upload et insights

Query latency: sub-second pour tableaux de bord

Modèle économique des DCRs

Modèles tarifaires typiques:

Per-query: $5-50 par query (variable)

Per-GB: $0.25-2.00 per GB scanned

Subscription: $10k-500k/an per account

Estimations pour PME:

Petite collab: 100 queries/mois = $500-5k/mois

Enterprise: subscription fixed

Cas d'usage ROI-positive

Quand DCR fait sens:

✓ Haute-valeur partnerships (B2B, co-marketing)

✓ Données propriétaires critiques (customer lists)

✓ Conformité réglementaire (banking, healthcare)

Quand ce n'est pas opportun:

✗ Données publiques ou acquises

✗ Analyses simples (pas besoin collaboration)

Stratégie de déploiement

Phase 1 - Pilot (1-2 mois):

Partenaire single, data subset, queries simples

Phase 2 - Validation (2-3 mois):

3-5 partenaires, mesurage ROI clair

Phase 3 - Scale (6+ mois):

10+ partenaires, processus opérationnel stable

Optimisation des requêtes

Performance:

Pré-aggregate: summarize avant DCR si possible

Index sur colonnes JOIN fréquentes

Partitionner large tables (par date, région)

Cost:

SELECT colonnes pertinentes (pas de SELECT *)

Batch queries hors-heures peak

Data Governance dans DCR

Processes:

Data catalog: metadata de toutes tables disponibles

Access control: approvals pour new partners

Data lineage: tracking source des données

Tools:

Data dictionaries (Collibra, Alation)

PII scanning tools (Immuta, Guardrails)

Tendances & Évolution

Federated learning: ML models trained across DCRs

Interoperability: standards émergeantes (OIDC)

Synthetic data: simulating insights without raw data

Blockchain: immutable audit trails

AI/ML: autonomous query recommendations

Vision 2025-2030

Où se dirige l'industrie:

Adoption mainstream: standard pour B2B data sharing

Ecosystems fermés: Google, Amazon, Adobe en dominants

Fragmenté mais mature: standards de query/audit

Nouvelle réglementation: EU Digital Market Act impact

Projet Final

En groupes de 3-4, choisissez un projet:

1. Projet A: Conception DCR pour startup (2-sided marketplace)
2. Projet B: Audit de sécurité DCR existante (case study)
3. Projet C: Business case ROI pour collab stratégique
4. Projet D: Implémentation PoC avec DuckDB

Délai: 2 semaines | Présentation: 15 min + 10 min questions

Conclusion

Les Data Clean Rooms redéfinissent la collaboration B2B dans l'ère post-cookies

- Confidentialité rencontre collaboration
- Conformité RGPD intégrée par design
- ROI réel pour partnerships stratégiques

Questions & Discussions

Vos questions sur Data Clean Rooms

Case Study: Colgate + Retailers Network

Contexte:

Colgate vend via 50+ retailers (Carrefour, E.Leclerc, Amazon)

Problème: pas de visibilité sur consumer behavior

Solution DCR:

Retailers upload: transaction data (anonymisé) + promotions

Colgate upload: campaign spend + media data

Analyses: promotion lift, price elasticity, basket affinity

Privacy-Preserving Analytics Patterns

Pattern 1: Hash Matching

Hash emails (SHA256) avant upload

Match sur hashs, jamais raw emails visibles

Pattern 2: Secure Multi-Party Computation

Calculs sur données encrypted

Aucun participant voit données autres

Implementation Checklist

- ☐ Identifier partner(s) stratégique(s)
- ☐ Conduct data audit (quelles données partager?)
- ☐ Evaluate platforms: coûts vs features
- ☐ Negotier DPA + terms
- ☐ Define KPIs & success metrics
- ☐ Run pilot avec subset de données
- ☐ Measure ROI, iterate ou scale

Competitive Advantage via DCRs

Pour Marques:

⚡ First-mover advantage: insights avant concurrents

Pour Retailers:

⚡ Supplier loyalty: co-marketing budgets

Pour Data Vendors:

⚡ New revenue: licensing data via DCR

Erreurs courantes à éviter

- Aggregation minimum too low (count < 5) = re-id risk
- Insufficient encryption = compliance audit failure
- Poor data quality = garbage in, garbage out
- No clear ROI metrics = hard to justify costs
- Overcomplicating first queries = analysis paralysis

Ressources pour approfondir

Documentation:

Google Ads Data Hub (ADH) documentation

AWS Clean Rooms guide + FAQ

Certifications:

AWS Certified Data Analytics - Specialty

Google Cloud Data Engineering

Merci!

Data Clean Rooms: Collaborating securely in the data economy

Projets finaux: due dans 2 semaines

Questions? Contactez l'instructeur

Good luck!